

E-Ticaret Verileri Üzerinde Davranışsal Müşteri Segmentasyonu

Yücel Berk Ünalı
Bilgisayar Mühendisliği

(Öğrenci)
Ankara Üniversitesi

(Üniversite)
Ankara, Türkiye
23291733@ogrenci.ankara.edu.tr

Ali Bahadır UYUMAZ
Bilgisayar Mühendisliği
(Öğrenci)
Ankara Üniversitesi

(Üniversite)
Denizli, Türkiye

22290875@ogrenci.ankara.edu.tr

Özet— E-ticarete rekabetin artması ve verinin büyümesi, klasik pazarlama stratejilerini yetersiz hale getirmiştir. İşletmelerin kısıtlı kaynaklarını boşa harcamaması için müşteri tabanını davranışsal özelliklere göre ayrıştırması artık bir tercih değil, operasyonel zorunluluktur. Bu araştırma kapsamında; RFM (Recency, Frequency, Monetary) metriklerini K-Means++ algoritmasıyla sentezleyen, otonom bir veri madenciliği boru hattı (pipeline) kurgulandı. Literatürdeki 30 farklı çalışmadan hareketle; K-Means'in en büyük handikapı olan 'başlangıç noktası hassasiyeti' ve 'küme sayısı belirsizliği' mercek altına alındı. Sorunu aşmak adına Dirsek (Elbow) yöntemi ve Siluet (Silhouette) analizi çapraz doğrulama mekanizması olarak sisteme entegre edildi. Ayrıca DBSCAN algoritması ile yapılan kıyaslamalı testlerde; verinin seyrek (sparse) yapısı nedeniyle DBSCAN'ın %3.4'lük veri kaybına sebep olduğu görüldü ve model dışı bırakıldı. Neticede K-Means++ kararlılığıyla oluşturulan dinamik segmentler (Şampiyonlar, Sadıklar vb.) üzerinden kişiye özel aksiyon planları üreten, Streamlit tabanlı uçtan uca bir karar destek sistemi ortaya kondu.

Keywords— *Müşteri Segmentasyonu, RFM Analizi, K-Means++, DBSCAN, CRM.*

I. GİRİŞ

Mobil devrim ve hızlanan internet altyapısı, son on yılda tüketici profilini neredeyse tanınmaz hale getirdi. Gomes ve ekibinin [11] de altını çizdiği gibi; e-ticaret artık mahalli bir yarış değil, küresel oyuncuların sahayı kapladığı sert bir pazar. Bu ortamda firmaların en büyük baş ağrısı, Yeni Müşteri Kazanım Maliyeti (CAC). Bu kalem, mevcut müşteri tutma maliyetini (Retention Cost) çoktan geride bıraktı. Artık Müşteri Yaşam Boyu Değerini (CLV) artırmak, şirketler için şık bir sunum hedefi değil, iflas etmemek için mecburi bir istikamettir.

Mevcut CRM süreçlerine mercek tuttuğumuzda, çarkları kilitleyen üç temel sorun hemen öne çıkıyor. İlki, ölçeklenebilirlik duvarı. Milyonlarca satırlık veriyi Excel gibi araçlarla veya manuel eforla işlemeye kalkmak, günümüz veri hacminde teknik bir imkansızlıktır. İkincisi, statik kural körlüğü. "1000 TL üzeri harcayan VIP'dir" gibi sabit ezberler,

enflasyonun ve pazarın anlık değiştiği bir ekonomide işlevini yitirir. Bu körlük, müşteriye yanlış sınıfa sokar. Üçüncüsü ise "herkese tek beden" yaklaşımı. Fırsatçı müşteriyle sadık müşteriye aynı kampanyayı sunmak, pazarlama bütçesini boşa harcamaktır. Farklı beklentilere aynı çözüm sunulamaz.

Bu projenin duruşu net: İnsanı aradan çekip otonom bir mimariyi devreye almak. Sistem ham veriyi alıyor, ayıklıyor ve segmentleri o günün şartlarına göre dinamik çiziyor. Literatürde genelde teorik anlatılan RFM ve K-Means entegrasyonu, bu çalışmada somut bir "Streamlit Dashboard" ürününe evrildi. Ortaya çıkan şey sadece pasif bir rapor ekranı değil, yöneticiye aksiyon aldırان canlı bir araç oldu.

II. LİTERATÜR TARAMASI

Müşteri sadakatini modellemek isteyen araştırmacılar, Lin ve Wu [19] tarafından "Yenilik", "Sıklık" ve "Parasal Değer" olmak üzere üç temel eksenle yapılandırılan RFM analizini endüstriyel bir standart olarak kabul etmektedir. Ne var ki, bu metriklerin herhangi bir ön işleme tabi tutulmadan algoritmaya verilmesi, Ezenkwu vd. [9] tarafından da kanıtlandığı üzere, matematiksel bir sapmaya (bias) yol açar; standardize edilmemiş veri, modeli orantısız şekilde yüksek ciro lu müşterilere odaklayarak segmentasyonun doğruluğunu zedeler.

Denetimsiz öğrenme süreçlerinde K-Means algoritması hesaplama hızıyla öne çıksa da, literatürde bu yöntemin kararlılığına dair ciddi şüpheler mevcuttur. Shirole vd. [25], analiz öncesinde ideal küme sayısının (k) bilinmemesini metodolojik bir kör nokta olarak nitelerken; Chitra ve Heikal [7], algoritmanın en kritik zafiyetinin başlangıç noktası seçimi olduğunu vurgular. Rastgele atanan merkezler, analizi yerel optimum (local optima) tuzaklarına sürükleyerek her denemede farklı sonuçlar alınmasına neden olabilir. Bu yapısal sorunlara alternatif olarak sunulan DBSCAN gibi yoğunluk tabanlı yöntemler ise, e-ticaret verisinin seyrek (sparse) doğasında parametre optimizasyonunun zorluğu nedeniyle beklenen esnekliği sağlayamamaktadır.

Mevcut çalışmalardaki bu belirsizlikleri aşmak adına, projemizde başlangıç merkezlerini olasılıksal olarak optimize eden K-Means++ mimarisi temel alınmış ve sonuçların tutarlılığı çapraz algoritmalarla doğrulanmıştır.

III. MATERYAL VE YÖNTEM

Mevcut çalışmanın teknik mimarisi, veriyi işleyip geçen standart bir analiz rutini olmaktan ziyade; algoritmaların matematiksel çekirdeğine inilen ve "sıfırdan inşa" (from scratch) felsefesiyle yapılandırılan özgün bir yazılım iskeleti üzerine kurgulanmıştır.

A. Veri Setleri ve Karakteristikleri

Geliştirilen modelin tek bir senaryoya hapsolmadığını teyit etmek ve farklı pazar dinamiklerindeki esnekliğini (generalizability) sınamak gayesiyle, analiz süreci iki ayrı veri evreninde yürütülmüştür:

1)Online Retail II (İngiltere): Araştırmanın ana omurgasını, UCI Machine Learning Repository'den temin edilen bu veri seti teşkil eder. 01/12/2009 ile 09/12/2011 tarihleri arasında kapsayan 541.909 satırlık bu veri yığını; bünyesinde barındırdığı iade faturaları ve eksik kayıtlarla, akademik temizlikten uzak, kaotik ve gürültülü bir "gerçek hayat" laboratuvarı işlevi görmektedir.

2)Sample Superstore (ABD): Modelin sektörler arası geçişkenliğini doğrulamak amacıyla, farklı bir perakende dikeyini temsil eden 9.994 satırlık bu veri seti, analize bir "sağlama" (validation) grubu olarak dahil edilmiştir.

B. Veri Ön İşleme ve Öznitelik Mühendisliği

Ham verinin, makine öğrenmesi algoritmaları tarafından yorumlanabilir analitik bir forma evrilmesi sürecinde, hazır kütüphanelerin standart yetenekleriyle yetinmek yerine, projeye özgü geliştirilen "Ön İşleme Sistemi" devreye alınmış ve şu prosedürler işletilmiştir:

1)Gürültü Temizliği (Noise Reduction): Ham verinin tabiatı, istatistiksel sapmalara gebe. Bu riski bertaraf etmek için, 'C' koduyla başlayan iade işlemleri ve CustomerID bilgisi eksik olan anonim kayıtlar, analitik bütünlüğü zedelememek adına veri havuzundan titizlikle ayıklanmıştır.

2)Davranışsal Metriklerin Türetilmesi (RFM): Müşterilerin dijital ayak izlerini sayısallaştırmak amacıyla; analizin yapıldığı tarih (t) referans noktası kabul edilerek, her bir müşteri için Yenilik (Recency), Sıklık (Frequency) ve Parasal Değer (Monetary) vektörleri aşağıdaki formülasyonla kurgulanmıştır:

Recency = t - max(date)
Frequency = Count(Unique(InvoiceNo))
Monetary = $\sum (Quantity \times UnitPrice)$

3)Aykırı Değer (Outlier) Yönetimi: Merkez tabanlı algoritmaların (özellikle K-Means) ortalamaya olan

aşırı hassasiyeti, uç değerlerin analizi manipüle etmesine zemin hazırlar. Bu handikapı aşmak için, istatistiksel dağılımın %99 (Q0.99) üzeri uç noktaları "törpülenerek" (winsorization) verinin merkezi eğilimi güçlendirilmiştir.

4)Logaritmik Dönüşüm ve Ölçekleme: Finansal verilerin doğası gereği sağa çarpık (right-skewed) bir dağılım sergilemesi, Öklid mesafesi hesaplamalarında ciddi bir dengesizlik yaratır. Veriyi normal dağılıma (Gaussian) yaklaştırmak için $\log(1+x)$ dönüşümü uygulanmış; hemen akabinde yüksek ciroolu "balina" müşterilerin, düşük hacimli müşterileri domine etmesini "dizginlemek" için Z-skoru standardizasyonu (Scaling) devreye sokulmuştur.

C. Algoritmik Mimari ve İmplementasyon

Projenin teknik derinliğini artırmak maksadıyla, algoritmalar birer "kara kutu" (black-box) olarak kullanılmamış, matematiksel teoriden taviz verilmeden manuel kodlamayla sisteme entegre edilmiştir.

1)Optimize Edilmiş K-Means (K-Means++): Uzaklık tabanlı çalışan bu mekanizma, "Atama" ve "Güncelleme" döngüsünü Öklid bağıntısı

$$d(p, q) = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$

üzerinden işletir. Standart K-Means'in en büyük zafiyeti olan ve analitik süreci şansa teslim eden "rastgele başlangıç noktası" problemini çözmek için, tarafımızca geliştirilen **init='k-means++'** modülü sisteme eklenmiştir. Bu modül, ilk merkezi rastgele atarken, sonraki merkezleri mevcutlara olan uzaklığın karesiyle ($D(x)^2$) orantılı bir olasılık dağılımıyla seçer. Böylece merkezler uzaya homojen dağılır ve algoritmanın yerel optimum tuzağına düşme riski minimize edilir.

2)Yoğunluk Tabanlı Yaklaşım (DBSCAN): K-Means'in küresel (spherical) küme varsayımına bir alternatif olarak, verinin yoğunluk haritasını çıkaran bu algoritma mimariye dahil edilmiştir. Veri noktalarının ϵ (Epsilon) yarıçapındaki komşuluklarını tarayan bu yöntem, yoğunluk eşikini (MinPts) aşan bölgeleri küme olarak tanımlarken, herhangi bir yapısal bütünlüğe dahil olamayan noktaları "Gürültü" (Noise) olarak etiketler. Bu yaklaşım, özellikle geometrik olarak düzensiz kümeleri tespit etme kabiliyeti nedeniyle, karşılaştırmalı analizde kritik bir referans noktası teşkil etmiştir.

IV. DENEY TASARIMI VE BULGULAR

Bölüm içeriği; model parametrelerinin optimizasyonu, algoritmaların performans testleri ve segmentlerin karakteristik analizini kapsar.

A. Hiperparametre Optimizasyonu

1) Optimum Küme Sayısının (K) Belirlenmesi:

'Küme Sayısı (K)' modelin başarısını doğrudan etkileyen faktördür. Tek bir metoda güvenmek risk yaratır. Hatayı önlemek adına iki teknik çapraz teste alındı:

- **Dirsek (Elbow) Yöntemi:**
- WCSS değerinin düşüş ivmesinin durduğu (kırılma) nokta tarandı.


$$WCSS = \sum_{j=1 \rightarrow k} \sum_{i \in C_j} \|x_i - \mu_j\|^2 \quad (6)$$

Analiz sonucunda, dirsek grafiği matematiksel olarak K=3'ü işaret etti. Fakat Siluet (Silhouette) analizinde K=4 seviyesinin kümeleri daha net ayırttığı görüldü. Tasarımda salt matematiksel kırılma yerine 'ayırışma kalitesi' baz alındı; K değeri 4 olarak kilitlendi.


- **Siluet (Silhouette) Analizi:** Kümelerin kendi içindeki tutarlılığı (cohesion) ve diğer kümelere olan uzaklığı (separation) ölçüldü.

$$S(i) = (b(i) - a(i)) / \max(a(i), b(i)) \quad (7)$$

Burada a(i) küme içi ortalama uzaklık, b(i) en yakın komşu kümeye olan uzaklıktır. Dirsek yöntemi K=3 önerisinde bulunsa da, Siluet analizi K=4 değerinin kümeler arası ayırışmayı daha net sağladığını ve negatif siluet skorunu minimize ettiğini gösterdi. Superstore verisinde ise sistem otomatik olarak K=3 değerine adapte oldu. Bu bulgular ışığında, Online Retail verisi için nihai karar **K=4** olarak belirlendi.



Şekil 1. Online Retail veri seti için Dirsek (Elbow) analizi.



Şekil 2. K-Means++ algoritmasının küme ayırışma başarısını gösteren Siluet Analizi.

2. DBSCAN Parametre Optimizasyonu

Yoğunluk tabanlı modelin Epsilon (ε) değeri, k-distance grafiğindeki ani yükseliş (knee point) referansıyla Online Retail verisinde 0.34 yapıldı.

1)Online Retail: ε=0.34, MinPts=10.

2)Superstore: ε=0.65, MinPts=10.

B. Algoritma Performans Karşılaştırması

Geliştirilen modülde Standart K-Means, K-Means++ ve DBSCAN yöntemleri kararlılık ve veri kaybı açısından yarıştı.

Tablo 1. Farklı kümeleme algoritmalarının performans ve stabilite karşılaştırması.

Algoritma	Parametre	Metrik (WCSS / Durum)	Sonuç
Standart K-Means	K=4	3708.59	Kararsız (Referans)
K-Means++	K=4	3708.13	Seçildi (Stabil)
DBSCAN	Eps=0.34	Gürültü (Noise): %3.4	Başarısız (Veri Kaybı)

DBSCAN Başarısızlığı ve Seyreklik Problemi:

Perakende verisindeki seyreklik (sparsity), DBSCAN algoritmasının noktaları bağlamasını engelledi. Sonuçta 1300 müşteri (%3.4) hiçbir kümeye giremedi, "Gürültü" (Noise) etiketiyle kapsam dışı kaldı. Ticari açıdan bu hacimde bir kitleyi analiz dışı bırakmak büyük risk olduğu için model elendi.

K-Means++ Seçimi: Standart algoritma rastgele merkez seçtiği için sonuçlar tutarsızdı. K-Means++ ise optimize başlangıç noktalarıyla her testte 3708.13 WCSS skorunu stabil şekilde üretti. Kararlılığı nedeniyle sisteme bu model eklendi.

C. Elde Edilen Segment Profilleri


K-Means++ (K=4) ile işlenen veriler, istatistiksel yapılarına göre dört ana gruba ayrıldı:

1)Champions (Şampiyonlar): Yakın zamanda işlem yapan, sık gelen ve ciroya en yüksek katkıyı veren lider grup.

2) Loyal Customers (Sadıklar): Harcama hacmi Şampiyonlar'ın gerisinde; ancak ziyaret sıklığı (Frequency) yüksek ve düzenli olan grup.

3)New/Potential (Geliştirilmeli): Aramıza yeni katılan ve harcama alışkanlığı henüz oturmamış kitle. Veri geçmişi az olsa da, doğru stratejiyle sadık müşteriye dönüşmeye adaydır.

4)Hibernating (Uykudakiler):İşlem hareketsizliği ortalama 195 günü buldu. Terk etme (churn) sinyali veren, en riskli segment.



Şekil 3. Müşteri segmentlerinin Recency, Frequency ve Monetary eksenlerindeki 3 boyutlu uzaysal dağılımı (Streamlit Arayüzü).

V. ÖNERİLEN SİSTEM VE AKSİYON PLANI

Çalışma teorik analizden öteye taşınmış; arayüz katmanı ve aksiyon üretim modülleriyle entegre çalışan uçtan uca bir Karar Destek Sistemi (DSS) kurgulanmıştır. Python Streamlit tabanlı arayüz, teknik uzmanlığı olmayan personelin veri madenciliği çıktılarını yorumlamasını ve aksiyon almasını sağlar.

A. Algoritmik Segment İsimlendirme ve Hibrit Skorlama

K-Means++ çıktısı olan ham matematiksel etiketler iş süreçlerinde yetersiz kalır. Bu veriyi işlenebilir bilgiye dönüştürmek amacıyla Hibrit Skorlama mekanizması kurulmuştur.

Sınıflandırma işleminde küme merkezleri tek kriter değildir. RFM çeyrek (quartile) toplamaları da hesaplamaya eklenir:

$$\text{Total_Score} = \text{R_Score} + \text{F_Score} + \text{M_Score} \quad (8)$$

Segment isimlendirmesi, elde edilen bu skorlara göre atanır:

1)Champions (Şampiyonlar): R, F ve M değerlerinin hepsi tavan seviyede.

2)Hibernating (Uykudakiler): Frekans (F) değeri baskın; ziyaret trafiği istikrarlı profil.

3)New Customers (Yeni Müşteriler): Recency (R) yüksek, veritabanına yeni kayıt. Frekans verisi henüz oluşmadı.

4) Hibernating(Risk Altındakiler): Tüm parametreler alt sınırdadır. R skoru kritik eşiğin altında.

B. Dinamik İndirim Stratejisi

"Tek Tip Kampanya" (One-size-fits-all) yaklaşımı yerine, her segmentin davranışsal karakteristiğine göre şu kurallar işletilir:

1)Champions Stratejisi: Fiyat duyarlılığı düşüktür. Kârlılığı azaltan indirimler yerine; aidiyet odaklı "Prestij" kurguları (Erken Erişim, VIP Hizmet) atanır.

2) Loyal Customers Stratejisi: Sepet tutarını artırmaya yönelik "Cross-Sell" (Çapraz Satış) önerileri tanımlanır.

3) New/Potential Stratejisi: Alışkanlık kazandırmak amacıyla, ikinci alışverişi tetikleyecek "Hoş Geldin" teşvikleri uygulanır.

4)Hibernating Stratejisi: Geri kazanımı en zor kitle. Müşteriyi yeniden aktive etmek (reactivation) için %30 seviyesinde agresif indirim oranları belirlenmiştir.


C. Teknik Entegrasyon ve UUID ile Kupon Üretimi

Sistemin nihai çıktısı, CRM altyapısına doğrudan işlenebilen aksiyon kodlarıdır. Geliştirilen otomasyon scripti, Python uuid kütüphanesi ile kişiye özel promosyon kodu üretir.

Süreç şu şekilde işler:

1. Algoritma müşteriyi segmente atar (Örn: Hibernating).
2. İlgili segmentin karar kuralını çeker (Örn: %30 İndirim).
3. Benzersiz kodu üretir ve veritabanına yazar: DON30-84AE-2F1.

Bu mimari sayesinde manuel operasyonlar (Excel vb.) devreden çıkarılmış; veri akışı tam otomasyona bağlanmıştır.



Şekil 4. Pazarlama ekipleri için geliştirilen otonom karar destek arayüzü. Sistem, seçilen segmente özel benzersiz kupon kodu ve mesaj üretmektedir.

VI. SONUÇ

Projenin nihai çıktısı, statik kurallardan bağımsız, kendi kararını veren otonom bir mimari yapısıdır. **Bu, temel hedefti.** Deneyisel süreçte teorik varsayımlar ile **gerçek data** arasında büyük bir ayrım olduğu görüldü.

Literatürde önerilse dahi, DBSCAN algoritması kullanılmadı. Verinin seyrek yapısı karşısında yetersiz kaldı. K-Means++ ile kıyaslandığında veri kaybı ciddi, bu sebeple model kapsamı dışına **alındı**. Buna karşılık, Elbow ve Silhouette metrikleriyle manuel optimize edilen K-Means++ algoritması **tercih edildi**. Veri setinin tamamının kapsanması bu şekilde **sağlandı**.

Elde edilen sonuçlar işletme stratejisini değiştirdi. Müşteriler dört net davranış grubuna ayrıldı. **'Tek tip reklam' devri böylelikle kapanmıştır.** Verimlilik odaklı 'doğru kişiye doğru teklif' dönemi **başlatıldı**.

Geliştirilen sistem, sadece akademik bir analiz olarak bırakılmadı. Python Streamlit arayüzü ile desteklenerek, teknik ekiplerden bağımsız kullanıma uygun ticari bir ürüne dönüştürüldü. **Karar vericilere doğrudan aksiyon üreten bir araç sunulmuş oldu.**

KAYNAKÇA

[1] F. Alzami, F. D. Sambasri, M. Nabila, R. A. Megantara, A. Akrom, R. A. Pramunendar, D. P. Prabowo, and P.

Sulistiawati, "Implementation of RFM method and K-Means algorithm for customer segmentation in e-commerce with Streamlit," *ILKOM Jurnal Ilmiah*, vol. 15, no. 1, pp. 32–44, 2023.

[2] P. Anitha and M. M. Patil, "RFM model for customer purchase behavior using K-Means algorithm," *Journal of King Saud University - Computer and Information Sciences*, vol. 34, no. 5, pp. 1785–1792, 2022.

[3] G. Aslantaş, M. Gençgöl, M. Rumelli, M. Özşarap, and G. Bakırlı, "Customer segmentation using K-Means clustering algorithm and RFM model," *Dokuz Eylül Üniversitesi Mühendislik Fakültesi Fen Ve Mühendislik Dergisi*, vol. 25, no. 74, pp. 491–503, 2023.

[4] D. A. Awaliyah, B. Prasetyo, R. Muzayanah, and A. D. Lestari, "Optimizing customer segmentation in online retail transactions through the implementation of the K-Means clustering algorithm," *Scientific Journal of Informatics*, vol. 11, no. 2, pp. 539–548, 2024.

[5] M. T. Ballestar, P. Grau-Carles, and J. Sainz, "Customer segmentation in e-commerce: Applications to the cashback business model," *Journal of Business Research*, vol. 88, pp. 407–414, 2018.

[6] S. Bandyopadhyay, S. S. Thakur, and J. K. Mandal, "Product recommendation for e-commerce business by applying principal component analysis (PCA) and K-means clustering: benefit for the society," *Innovations in Systems and Software Engineering*, vol. 17, no. 1, pp. 45–52, 2021.

[7] J. Chitra and J. Heikal, "Customer segmentation using the K-Means clustering algorithm in foreign banks in Indonesia," *Journals Institute of Accounting Research and Novation (IARN)*, 2024.

[8] O. Doğan, E. Ayçin, and Z. A. Bulut, "Customer segmentation by using RFM model and clustering methods: A case study in retail industry," *International Journal of Contemporary Economics and Administrative Sciences*, vol. 8, no. 1, pp. 1–19, 2018.

[9] C. P. Ezenkwu, S. Ozuomba, and C. Kalu, "Application of K-Means algorithm for efficient customer segmentation: A strategy for targeted customer services," *International Journal of Advanced Research in Artificial Intelligence*, vol. 4, no. 10, pp. 40–44, 2015.

[10] R. M. Fauzan and G. Alfian, "Segmentasi pelanggan e-commerce menggunakan fitur recency, frequency, monetary (RFM) dan algoritma klasterisasi K-Means," *JISKA (Jurnal Informatika Sunan Kalijaga)*, vol. 9, no. 3, pp. 170–177, 2024.

[11] M. A. Gomes and T. Meisen, "A review on customer segmentation methods for personalized customer targeting in e-commerce use cases," *Information Systems and e-Business Management*, vol. 21, no. 3, pp. 527–570, 2023.

- [12] R. Govindaraj, J. Ramkumar, J. Bhuvaneswari, S. Venugopal, S. K. Chandra Kala, and R. Karthick, "Enhancing customer segmentation insights by using RFM + discount proportion model with clustering algorithms," *International Journal of Advanced Computer Science and Applications*, vol. 15, no. 3, pp. 856–862, 2024.
- [13] R. Govindaraj *et al.*, "Enhancing customer segmentation: RFM analysis and K-Means clustering implementation," in *Hybrid and Advanced Technologies: Proceedings of the International Conference on Hybrid and Advanced Technologies (ICHAT 2024)*, S. P. J. Christydass, N. Nurhayati, and S. Kannadhasan, Eds., 2025.
- [14] S. Idowu and S. Kattukottai, "Customer segmentation based on RFM model using K-Means, Hierarchical and Fuzzy C-Means clustering algorithms," *ResearchGate*, 2020.
- [15] J. M. John, O. Shobayo, and B. Ogunleye, "An exploration of clustering algorithms for customer segmentation in the UK retail market," *Analytics*, vol. 2, no. 4, pp. 809–823, 2023.
- [16] M. F. A. Kadir and A. Achyar, "Customer segmentation on online retail using RFM analysis: Big data case of Bukku.id," in *Proceedings of the International Conference on Environmental Awareness for Sustainable Development (ICEASD)*, 2019.
- [17] M. Khajvand, K. Zolfaghar, S. Ashoori, and S. Alizadeh, "Estimating customer lifetime value based on RFM analysis of customer purchase behavior: Case study," *Procedia Computer Science*, vol. 3, pp. 57–63, 2011.
- [18] P. Li, C. Wang, J. Wu, and R. Madleňák, "An e-commerce customer segmentation method based on RFM weighted K-means," in *2022 International Conference on Management Engineering, Software Engineering and Service Sciences (ICMSS)*, pp. 61–68, 2022.
- [19] S. Y. Lin and H. H. Wu, "A review of the application of RFM model," *African Journal of Business Management*, vol. 4, no. 19, pp. 4199–4206, 2010.
- [20] T. Mammadov and F. Mammadova, "Behavioral segmentation of customers: RFM model and K-Means application," *EURASIA: Economics & Business*, vol. 3, no. 93, pp. 13–32, 2025.
- [21] T. Özcan, "Customer segmentation using RFM analysis and clustering algorithms in express delivery industry," *Eurasian Business & Economics Journal*, vol. 32, no. 32, pp. 47–56, 2023.
- [22] M. Sarkar, A. R. Puja, and F. R. Chowdhury, "Optimizing marketing strategies with RFM method and K-Means clustering-based AI customer segmentation analysis," *Journal of Business and Management Studies*, vol. 6, no. 2, pp. 54–60, 2024.
- [23] A. Savic, G. Bjelobaba, S. Janicijevic, and H. Stefanovic, "An application of PCA based K-Means clustering for customer segmentation in one luxury goods company," in *Proceedings of the UBT International Conference*, 2019.
- [24] N. H. Shah, W. Khalid, A. Ahmad, J. A. Ghaffar, and M. Tahir, "The effect of customer relationship management on customer retention: The mediating role of customer satisfaction and effective commitment," *ResearchGate*, 2023.
- [25] R. Shirole, L. Salokhe, and S. Jadhav, "Customer segmentation using RFM model and K-Means clustering," *International Journal of Scientific Research in Science and Technology*, vol. 8, no. 3, pp. 591–597, 2021.
- [26] Y. Syahra, A. Fadlil, and H. Yuliansyah, "Customer segmentation using RFM and K-Means clustering to support CRM in retail industry," *Sinkron: Jurnal Dan Penelitian Teknik Informatika*, vol. 9, no. 3, pp. 1120–1131, 2025.
- [27] K. Tabianan, S. Velu, and V. Ravi, "K-Means clustering approach for intelligent customer segmentation using customer purchase behavior data," *Sustainability*, vol. 14, no. 12, p. 7243, 2022.
- [28] B. G. Vo, H. D. S. Van, N. D. Van, and H. D. Huynh, "Customer segmentation: Automatic K-Optimization and RFM-Based K-Means clustering," in *Proceedings of the 2025 5th International Conference on AI, Mechatronics and Surveying (AIMS '25)*, 2025.
- [29] C. G. Wong, G. G. Tong, and S. C. Haw, "Exploring customer segmentation in e-commerce using RFM analysis with clustering techniques," *Journal of Telecommunications and the Digital Economy*, vol. 12, no. 3, pp. 97–125, 2024.
- [30] Z. Wu and L. Jin, "Research on segmenting e-commerce customer through an improved K-Medoids clustering algorithm," *Computational Intelligence and Neuroscience*, vol. 2022, Art. no. 9930613, 2022.