

E-Ticaret Verileri Üzerinde Davranışsal Müşteri Segmentasyonu

Yücel Berk Ünal
Bilgisayar Mühendisliği
(Öğrenci)

Ankara Üniversitesi
(Üniversite)

Ankara, Türkiye

23291733@ogrenci.ankara.edu.tr

Ali Bahadır Uyumaz
Bilgisayar Mühendisliği
(Öğrenci)

Ankara Üniversitesi
(Üniversite)

Denizli, Türkiye

22290875@ogrenci.ankara.edu.tr

Özet— E-ticaret ortamındaki artan rekabet, işletmeleri müşteri odaklı stratejilere yöneltmektedir. Müşteri segmentasyonu, kişiselleştirilmiş yaklaşımlar için temel bir adımdır. Bu literatür taraması, davranışsal müşteri segmentasyonu amacıyla Recency, Frequency, Monetary (RFM) analizi ile K-Means kümeleme algoritmasının birleşimini kullanan çalışmaları ve metodolojileri incelemektedir. İnceleme kapsamında, RFM metriklerinin müşteri değerini nasıl temsil ettiği ve K-Means'in bu metriklerle müşterileri nasıl gruplandığı analiz edilmiştir. RFM ve K-Means kombinasyonunun e-ticaret, perakende ve hizmet sektörlerinde yaygın olarak kullanıldığı ve pratik segmentasyonlar (örn. 'Şampiyonlar', 'Riskli Müşteriler') ürettiği tespit edilmiştir. Alternatif yaklaşımlar da değerlendirilmiştir; Hiyerarşik Kümeleme, Fuzzy C-Means, DBSCAN gibi farklı kümeleme algoritmaları, Autoencoder gibi Derin Öğrenme teknikleri ve Müşteri Yaşam Boyu Değeri (CLV) gibi alternatif değer modelleri güncel araştırma alanları olarak belirlenmiştir. Çalışma ayrıca metodolojik zorluklara da işaret etmektedir: RFM'in genellikle işlemsel verilerle sınırlı kalması, K-Means için optimal küme sayısının (k) belirlenmesindeki güçlükler ve algoritmanın aykırı değerlere hassasiyeti bu zorluklar arasındadır. Sonuç olarak, bu entegre yaklaşımın, belirtilen kısıtlamalara rağmen, davranışsal müşteri segmentasyonu için hala yaygın, hızlı ve yorumlanabilir bir temel yöntem sunduğu sonucuna varılmıştır.

Anahtar Kelimeler—Müşteri Segmentasyonu, RFM Analizi, K-Means Kümeleme, Veri Madenciliği, E-ticaret

I. GİRİŞ

E-ticaret son on yılda çok değişti. İnternet hızlandı. Akıllı telefonlar yaygınlaştı. İnsanların alışveriş şekli farklılaştı (Gomes vd., 2023). Pazar bu yüzden çok daha rekabetçi. Firmalar artık sadece yandaki dükkanla değil, tüm dünyayla yarışıyor (Bandyopadhyay vd., 2021). Bu ortamda iş yapmak zorlaştı.

Eskiden firmalar hep yeni müşteri arardı. Gelen gelsin, satışı yap, sonraki gelsin. Bu artık pek mantıklı değil. Yeni müşteri bulmak, eldekini tutmaktan daha pahalı (Shah vd., 2023). Müşteri sadakati bu yüzden önemli oldu. Sadık müşteri daha sık gelir, daha çok harcar. Müşterinin değerini anlamak için de geçmişte ne yaptığına bakmak lazım diyorlar (Khajvand vd., 2011).

Müşteriyi nasıl sadık yaparsın? Onu tanıyarak. Ama bu kolay değil. Herkes farklı. Kimi az gelir, kimi sık. Kimi az harcar, kimi çok. Farkları görmek için müşteri segmentasyonu kullanılıyor. Yani, kalabalığı anlamlı gruplara bölmek (Aslantaş vd., 2023). O zaman her gruba farklı yaklaşılabilir.

Burada önemli bir şey var: Neye göre böleceksin? Yaş, cinsiyet bir yere kadar. E-ticarete asıl olay "davranış" (Ballestar vd., 2018). Müşteri ne yapmış, ona bakmak lazım. En son ne zaman gelmiş? Ne sıklıkta geliyor? Ne kadar harcıyor? Bu soruların cevabı, müşterinin değerini anlamak için daha önemli (Tabianan vd., 2022). Davranış ve demografi birleşince daha da iyi oluyor.

RFM ve K-Means, bu davranışsal iş için sıkça kullanılan iki yöntem. RFM pratik bir analiz: Müşterinin değerini üç şeyle ölçüyor: Recency, Frequency, Monetary (Lin & Wu, 2010). Yani ne kadar yeni, ne kadar sık, ne kadar harcıyor. Bu size bir fikir veriyor. K-Means ise bu RFM bilgilerini alıp, müşterileri otomatik gruplara ayıran bir algoritma (Ezenkwu vd., 2015). Kim kime benziyor, kim değerli, kim gidici, bunu buluyor.

Bu çalışmada da bu konuya bakıyoruz. E-ticaret firmaları RFM ve K-Means'i nasıl kullanıyor? Ne sonuçlar alıyorlar? İkinci bölümde bu iki yöntemin teknik detaylarına ineceğiz. Üçüncü bölümde, gerçek dünyadan örneklere bakacağız. Kim ne yapmış? Başka ne yöntemler kullanılmış? Bunları göreceğiz. Dördüncü bölümde ise bu yöntemlerin nerede tıkandığını, zorluklarını konuşacağız. Beşinci bölümde de tüm bu incelemeyi toparlayacağız.

II. TEMEL METODOLOJİLER VE KAVRAMLAR

Müşterileri gruplara ayırmak için veri madenciliğinde bir sürü farklı yöntem var. Ama e-ticaret verilerine bakınca, iki tanesi basit ve yorumlaması kolay olduğu için hep öne çıkıyor. Bizim çalışmamızın da temelini bu iki araç oluşturuyor: birincisi müşterinin "değerini" ölçmek için RFM analizi, ikincisi de bu müşterileri gruplamak için K-Means algoritması.

A. Müşteri Değer Metriği Olarak RFM Analizi

RFM, aslında Müşteri İlişkileri Yönetimi (CRM) dünyasında ('Enhancing Customer...', t.y.) yıllardır bilinen bir model. Olayı, müşterinin satın alma geçmişine bakarak ona bir puan vermek (Lin & Wu, 2010). Tüm mantığı da "her müşteri aynı değildir" fikrine dayanıyor.

Peki farkı nasıl anlarız? RFM bize üç şeye bakmamızı söylüyor: Recency (Yenilik), Frequency (Sıklık) ve Monetary (Parasal Değer). Yani, müşteri en son ne zaman gelmiş? Ne kadar sık geliyor? Ve ne kadar para bırakmış? (Ballestar vd., 2018). Bu üçü çok kritik. Dün gelen birinin yarın da gelme ihtimali, altı ay önce gelenden çok daha fazladır. Sık gelen de sadakatini gösterir. En çok harcayan da doğal olarak en kârlı olandır.

RFM'in yaptığı şey, bu üç bilgiyi alıp (mesela 1'den 5'e kadar) basitçe puanlamak (skorlama). Örneğin, en yeni gelen müşteriler 'R' için 5 puan alırken, en eskiler 1 puan alır. En sık gelenler 'F' için 5 puan, en çok harcayanlar da 'M' için 5 puan alır.

Sonuçta, bu puanlama sayesinde, her müşterinin '5-5-5' (şampiyon müşteri) veya '1-1-1' (kaybedilmiş müşteri) gibi bir skoru olur. Bu da o karmaşık işlem kayıtlarını, pazarlama ekibinin hemen anlayacağı basit, karşılaştırılabilir bir şeye dönüştürür.


B. Denetimsiz Öğrenmede K-Means Kümelemesi

Tamam, şimdi elimizde müşterilerin RFM puanları var. Bunları 'otomatik' olarak nasıl gruplayacağız? İşte burada denetimsiz öğrenme (unsupervised learning) denilen bir yaklaşım devreye giriyor (Alzami vd., 2023). 'Denetimsiz' diyoruz çünkü elimizde 'iyi' ya da 'kötü' müşteri gibi hazır etiketler yok. Algoritmanın kendisi, verideki benzerliklere bakıp grupları kendi bulmaya çalışıyor.

K-Means de bu işi yapan en popüler algoritmalarından biri (Aslantaş vd., 2023). Mantığı aslında çok sezgisel. Algoritmaya önce 'bana 4 küme bul' gibi bir 'K' sayısı veriyorsunuz. (Bu işin en zor kısmı bu). Sonra K-Means, bu 4 kümeyi temsil etmesi için rastgele 4 tane 'merkez' (centroid) seçiyor. Ve bir döngü başlatıyor:

Önce her müşteriye 'sen bu 4 merkezden hangisine en yakınsın?' diye sorup o gruba atıyor. Herkes bir gruba girince, bu defa o 4 grubun 'tam ortasını' (RFM ortalamasını) yeniden hesaplıyor. E, merkezler kayınca, müşterilerin de yakınlıkları değişiyor. Bu yüzden algoritma tekrar soruyor: 'Yeni merkezlere göre kim kime yakın?' Bu

'ata-güncelle' süreci, artık merkezlerin yeri hiç oynamayana, yani sistem bir dengeye oturana kadar devam ediyor (Tabianan vd., 2022).



Şekil 1: K-means Çıktıları

Algoritmanın bütün amacı, herkesin kendi merkezine olabildiğince yakın olmasını sağlamak, yani küme içi mesafeyi en aza indirmek (Aslantaş vd., 2023). Bu algoritmayı herkesin sevmesinin nedeni de bu: basit, uygulaması kolay ve büyük verilerde bile hızlı çalışıyor. Tabii ki o 'K' sayısını en başta doğru bilmek veya başlangıç merkezlerinin nerede olduğu gibi dertleri de var. Bunlara da sonraki bölümlerde bakacağız.

C. Literatürde RFM+K-Means Uygulama Adımları

RFM puanlarını hesaplamak ve K-Means'in mantığını anlamak için teorik tarafıdır. Ama bu ikisini pratikte birleştirmek için literatürde artık yerleşmiş bazı önemli adımlar var. K-Means temelde mesafeye göre çalıştığından, bu adımlar sonuçların ne kadar doğru olacağını doğrudan belirliyor. Başarılı bir RFM temelli segmentasyon için çalışmalar genellikle şu üç adımı atıyor:


1) *Veriyi Normalleştirme ve Dönüştürme:* Bu adım çok önemlidir. RFM metrikleri farklı şeyler ölçer. Recency 'gün', Frequency 'adet', Monetary ise 'para'dır. Ölçekleri ve birimleri tamamen farklıdır. Bu veriyi olduğu gibi K-Means'e vererseniz, algoritma en büyük sayılara sahip olana (genelde Monetary) odaklanır. Diğerlerinin pek bir anlamı kalmaz.

Bu sorunu çözmek için neredeyse tüm çalışmalar, kümelemeden önce veriyi bir şekilde normalleştirir veya standartlaştırır (Ezenkwu vd., 2015; Vo vd., 2025). Ya Min-Max ile her şeyi 0 ile 1 arasına getiriyorlar (Syahra vd., 2025) ya da Z-Skoru kullanarak ortalamayı sıfır, standart sapmayı bir yapıyorlar (Aslantaş vd., 2023).

Ayrıca, RFM verisinde, özellikle Frequency ve Monetary'de bir çarpıklık olur. Çoğu müşteri az alışveriş yapar ve az harcar. Ama çok az sayıda müşteri de aşırı fazla harcama yapar. K-Means bu tür çarpık dağılımları pek sevmez. Bu yüzden veriyi daha 'normal' hale getirmek için logaritma

veya Box-Cox gibi dönüşümler de sıkça başvuru olan yollardır (Wong vd., 2024; Vo vd., 2025).

2) *Doğru Küme Sayısını (K) Bulma*: K-Means'in en can sıkıcı yanı, kaç küme (K) istediğinizi en başta sizin söylemeniz gerektiridir. Literatürde bunu kesin bulan sihirli bir formül yok. Ama en yaygın kullanılan pratik yöntem Dirsek Yöntemi (Elbow Method) (Shirole vd., 2021; Alzami vd., 2023). Yöntemin mantığı basit: Farklı K değerleri (örneğin 2'den 10'a) için modelin toplam hatası (WCSS) hesaplanır. Bu hata değerlerini bir grafiğe döküyorlar. Grafikte hatanın düşüş hızının yavaşladığı bir nokta oluyor, yani "dirsek" gibi görünen yer genellikle en iyi K sayısı olarak kabul ediliyor (Vo vd., 2025).



Şekil 2 : Dirsek metodu grafiği

3) *Kümelerin Kalitesini Kontrol Etme (Validation)*: Dirsek Yöntemi her zaman net bir fikir vermeyebilir. Grafik bazen yavaşça eğilebilir ve doğru K sayısını seçmek zorlaşabilir. Bu nedenle araştırmacılar, seçtikleri K'yı teyit etmek ve kümelerin kalitesini ölçmek için başka metriklerle de bakarlar. Bu alanda en popüler olanı Siluet Skoru'dur (Silhouette Score) (Anitha & Patil, 2022; Shirole vd., 2021; John vd., 2023). Bu skor -1 ile +1 arasında bir puan verir. Kümelerin kendi içinde ne kadar tutarlı, diğerlerinden ne kadar ayrı olduğunu gösterir. Puan yüksekse (genelde 0.5 üstü), küme yapısı iyidir. Siluet Skoru'nun yanında, Davies-Bouldin Endeksi (DBI) (Fauzan & Alfian, 2024) ve Calinski-Harabasz Endeksi (CHI) (Fauzan & Alfian, 2024) gibi metrikler de kümelerin ne kadar iyi olduğunu anlamak için sıkça kullanılır.

III. GÜNCEL GELİŞMELER VE SON TEKNOLOJİ ANALİZİ

Önceki bölümde RFM ve K-Means'in teorik altyapısını gördük. Şimdi bu yöntemlerin gerçek dünyadaki uygulamalarına ve alanın nereye doğru gittiğine, yani alternatif yaklaşımlara bakalım.

A. RFM ve K-Means Entegrasyonunu Kullanan Güncel Çalışmalar (Gerçek Dünya Örnekleri)

RFM skorlarını hesaplayıp K-Means ile gruplama yapmak, sadece teorik bir egzersiz değil; gerçekten de birçok firmanın ve araştırmacının sıkça başvurduğu pratik bir yöntem. Son yıllardaki yayınlara baktığımızda, bu ikilinin e-ticaret sitelerinden (Fauzan & Alfian, 2024) fiziksel mağazalara (Doğan vd., 2018), hatta kargo şirketlerine (Özcan, 2023) kadar çok çeşitli alanlarda kullanıldığını görüyoruz. Peki bu çalışmalar bize ne anlatıyor?

1) *E-ticaret ve Perakende*: Bu alanlar, yöntemin en doğal uygulama sahası. Örneğin, Fauzan ve Alfian (2024), bir e-ticaret sitesinin verilerini analiz ederek RFM skorları üzerinden K-Means ile müşterileri 'Yeni', 'Potansiyel', 'Sadık' ve 'Şampiyon' olarak dört temel kategoriye ayırmışlar. Her grubun davranışsal profiline göre farklı pazarlama stratejileri geliştirilebileceğini göstermişler. Kadir ve Achyar (2019) ise online kitapçı Bukku.id için yaptıkları analizde, hangi müşteri gruplarının platformu daha yoğun kullandığını ve daha yüksek harcama yaptığını belirlemişler. Bu tür bilgiler, promosyonların kime odaklanması gerektiği konusunda yol gösterici oluyor.

2) *Üretim ve Hizmet*: Yöntem sadece mal satan yerlerle sınırlı kalmıyor. Aslantaş ve ekibi (2023), Vestel gibi bir üreticinin müşteri verilerini incelemiş. Çalışmalarında, RFM ve K-Means ile buldukları grupların, müşterinin gelecekteki değerini tahmin etmeye yarayan Müşteri Yaşam Boyu Değeri (CLV) ile anlamlı bir ilişkisi olduğunu bulmuşlar. Yani, RFM skorları sadece geçmiş değil, bir ölçüde gelecekteki potansiyeli de yansıtabiliyor. Hizmet sektöründen bir örnek olarak Özcan (2023), bir kargo firmasının müşterilerini gruplamış. Çalışması, her gruba özel pazarlama taktikleri önermiş; mesela, eskiden sık gelen ama artık seyrek gelen 'Uyumakta Olan Sadıklar' grubunu yeniden kazanmak için özel kampanyalar tasarlamayı tavsiye etmiş.

Görüldüğü üzere, bu çalışmaların ortak amacı, karmaşık müşteri işlem kayıtlarını alıp, RFM ve K-Means kullanarak (Shirole vd., 2021) "Şampiyonlar", "Risk Altındakiler" gibi pazarlama profesyonellerinin kolayca yorumlayabileceği, aksiyon alınabilir gruplara (Sarkar vd., 2024) dönüştürmek. Bu da şirketlerin sınırlı kaynaklarını daha etkin kullanmalarına yardımcı oluyor.

B. Müşteri Segmentasyonunda Alternatif ve İleri Düzey Teknikler (Alternatif Yöntemler)

Ancak, müşteri segmentasyonu dünyası sadece RFM ve K-Means'ten ibaret değil. Bu yöntemlerin de bazı kısıtlamaları olduğu için (ki bunlara bir sonraki bölümde değineceğiz), araştırmacılar sürekli olarak alternatif ve daha gelişmiş yollar arıyor (Gomes vd., 2023). Peki nedir bu alternatifler?

1) *Alternatif Kümeleme Algoritmaları*: K-Means yerine başka kümeleme algoritmaları da mevcut ve bazı durumlarda daha iyi sonuçlar verebiliyorlar. Örneğin Hiyerarşik Kümeleme, baştan kaç küme ('k') istediğinizi bilmenizi gerektirmez, size bir küme hiyerarşisi sunar. Bazı karşılaştırmalı çalışmalarda (Idowu & Kattukottai, 2020), RFM verisi üzerinde Hiyerarşik Kümelemenin, K-Means'e göre belirli küme kalitesi metriklerinde daha başarılı olduğunu gösteren sonuçlar bulunmuştur. Fuzzy C-Means ise, K-Means'in aksine, bir müşterinin birden fazla kümeye ait olabileceğini kabul ederek daha esnek bir yaklaşım sunar. Verinizde çok fazla aykırı değer (outlier) varsa veya kümeleriniz yuvarlak değil de daha karmaşık şekillerdeyse, DBSCAN gibi yoğunluk tabanlı algoritmalar daha uygun olabilir. K-Means'in aykırı değerlere olan hassasiyetini azaltmak amacıyla K-Medoids de bir alternatiftir; bu algoritma merkezleri gerçek veri noktaları arasından seçtiği için uç değerlerden daha az etkilenir (Wu & Jin, 2022). K-Means'in başlangıç noktasına bağlı kalma sorununu aşmak için ise pratikte genellikle K-Means++ gibi daha akıllı başlangıç stratejileri kullanılır. Ayrıca, kümeleme öncesinde PCA (Temel Bileşen Analizi) gibi boyut azaltma teknikleri uygulanarak hem verinin görselleştirilmesi kolaylaştırılabilir hem de K-Means'in performansı iyileştirilebilir (Bandyopadhyay vd., 2021; Savic vd., 2019).

2) *Derin Öğrenme Tabanlı Segmentasyon*: Teknolojinin en ileri noktasında ise derin öğrenme modelleri yer alıyor. Özellikle Autoencoder (Öz-kodlayıcı) gibi yapılar, müşterinin sadece RFM skorlarını değil, potansiyel olarak yüzlerce farklı davranışsal verisini (tıkladığı ürünler, sitede geçirdiği süre vb.) kullanarak müşteriyi tanımlayan daha zengin ve kompakt bir 'temsil' (representation) öğreniyor. Bu öğrenilmiş 'temsil' üzerinde kümeleme yapmanın, genellikle ham veri üzerinde yapılan kümelemeden daha iyi segmentasyonlar sağladığı akademik literatürde gösterilmektedir (Gomes vd., 2023). Bu yaklaşım henüz endüstri standardı olmasa da, gelecekte öneminin artması bekleniyor.

3) *Alternatif Değer Modelleri*: Alternatif arayışları sadece kümeleme algoritmalarıyla sınırlı değil. Müşterinin değerini ölçmek için kullanılan RFM modelinin kendisi de tek seçenek değil. RFM'in 'geçmişe odaklı' olması bir eleştiri konusudur. Bu nedenle, müşterinin 'gelecekteki' değerini tahmin etmeye çalışan Müşteri Yaşam Boyu Değeri (CLV) modelleri de yaygın olarak kullanılmaktadır (Khajvand vd., 2011). Çoğu zaman RFM, bu CLV hesaplamaları için bir girdi veya başlangıç noktası olarak işlev görür. Örneğin, Khajvand ve ekibi (2011), RFM ile belirledikleri segmentlerin CLV'sini tahmin ederek her gruba özel müşteri tutma stratejileri ('en iyi müşterilere VIP programı gibi') önermişlerdir. Bir başka yaklaşım ise standart RFM'e (R, F, M) müşterinin kullandığı indirimler ('Enhancing Customer...', t.y.), iade alışkanlıkları gibi ek bilgiler katarak daha kapsamlı "Geliştirilmiş RFM" (bazen RFM+ veya W-RFM olarak da geçer) modelleri oluşturmaktır (Li vd., 2022). Tüm bu çabaların ortak amacı, müşteriyi daha derinlemesine anlamak ve değerini daha isabetli bir şekilde ölçmektir.

IV. ALANDAKİ ZORLUKLAR VE AÇIK ARAŞTIRMA ALANLARI

RFM ve K-Means ikilisi, segmentasyon için hızlı, anlaşılır ve güçlü bir temel sağlasa da (Anitha & Patil, 2022; Ezenkwu vd., 2015), bu yöntemlerin de "mükemmel" olmadığını kabul etmek gerekir. Literatürdeki çalışmalar, bu iki metodolojinin de kendilerine has bazı kısıtlamaları ve zorlukları olduğunu sıkça vurgulamaktadır (Gomes vd., 2023). Bu zorluklar, aynı zamanda bu alanda hala araştırma yapılabilecek "açık alanları" da göstermektedir.

A. RFM Metodolojisine İlişkin Kısıtlamalar

RFM, müşteri değerini anlamak için harika bir başlangıç noktasıdır (Lin & Wu, 2010), ancak bazı kör noktaları vardır. Karşılaşılan en yaygın kısıtlamalardan biri, RFM'in neredeyse tamamen "satın alma" verilerine, yani işlemsel (transactional) verilere odaklanmasıdır (Shirole vd., 2021). Modern e-ticarette, bir müşterinin değeri sadece ne kadar harcadığıyla ölçülmez. Müşterinin siteyi kaç kez ziyaret ettiği, hangi ürünlere baktığı, sepete ürün ekleyip almaması (cart abandonment) veya ürünlere yorum yapması gibi işlemsel olmayan (non-transactional) davranışlar, müşterinin "etkileşim" (engagement) düzeyini gösteren çok değerli verilerdir (Gomes vd., 2023). Standart RFM modeli bu zengin veriyi genellikle göz ardı eder.

Bir diğer tartışma konusu ise RFM metriklerinin ağırlığıdır. Klasik yaklaşım R, F ve M'nin sanki hepsi eşit derecede önemliymiş gibi davranır (Lin & Wu, 2010). Oysa bir sektör (örn: mobilya) için "Parasal Değer" (M) çok önemliyken, başka bir sektör (örn: market alışverişi) için "Sıklık" (F) veya "Yenilik" (R) çok daha kritik olabilir. Bazı çalışmalar, bu metrikleri K-Means'e sokmadan önce ağırlıklandırmayı (Weighted-RFM) önerse de (Lin & Wu, 2010), bu ağırlıkların nasıl belirleneceği de ayrı bir problemdir.

Son olarak, Bölüm III'te de değinildiği gibi, RFM'in "geçmişe odaklı" (backward-looking) olması bir kısıtlamadır (Ballestar vd., 2018). Geçmişte "şampiyon" olan ama artık şirketi terk etmiş bir müşteriyi, RFM skoru hala yüksek gösterebilir ve şirket o müşteriyi geri kazanmak için boş yere kaynak harcayabilir.

B. K-Means Kümelemesindeki Zorluklar

K-Means'in de pratikte uygulanmasını zorlaştıran bazı kronik sorunları vardır. Bu algoritmayı kullanan herkesin karşılaştığı ilk ve belki de en büyük zorluk, optimal küme sayısını, yani "k" değerini baştan belirleme gerekliliğidir (Chitra & Heikal, 2024).

Bunu bulmak için Dirsek (Elbow) Yöntemi (Shirole vd., 2021; Fauzan & Alfian, 2024) veya Siluet Skoru (Silhouette Score) (Vo vd., 2025) gibi teknikler yaygın olarak kullanılmaktadır. Ancak bu yöntemlerin ürettiği grafikler, özellikle gerçek hayatın "kirli" verilerinde, her zaman bize net bir "kırılma noktası" veya bariz bir "en iyi k" değeri vermez (Wu & Jin, 2022). Çoğu zaman analistin, iş bilgisine (business knowledge) dayanarak öznel bir karar vermesi gerekir.

K-Means'in bir diğer bilinen zayıflığı, aykırı değerlere (outliers) karşı çok duyarlı olmasıdır (John vd., 2023). Örneğin, bir kümedeki müşterilerin çoğu 100-200 TL arası harcama yapmışken, araya giren tek bir 50.000 TL'lik (ama belki de hatalı girilmiş) bir işlem, o kümenin merkezini (centroid) tamamen kendine doğru çekerek tüm segment yapısını bozabilir (Savic vd., 2019).

Son olarak, K-Means'in başlangıç merkezlerine duyarlılığı da bir zorluktur. Algoritma, küme merkezlerini ilk başta rastgele seçer. Bu yüzden algoritmayı aynı veri seti üzerinde iki farklı zamanda çalıştırdığınızda, bu rastgele başlangıçlar yüzünden birbirinden farklı kümeleme sonuçları (local optima) elde etme ihtimaliniz vardır. Her ne kadar bu sorunu büyük ölçüde hafifleten K-Means++ (Bandyopadhyay vd., 2021) gibi daha akıllıca başlangıç yöntemleri geliştirilmiş olsa da, bu hala dikkat edilmesi gereken bir konudur.

V. SONUÇ

Bu literatür taramasının sonunda e-ticaret pazarının artık çok daha rekabetçi olduğunu görüyoruz. İşletmeler müşterilerini anlamak ve onlarla sağlam bağlar kurmak zorunda. Davranışsal segmentasyon işte bu yüzden önemli bir strateji. Baktığımız çalışmalar şunu gösteriyor: RFM analizi ile K-Means kümelemeyi birleştirmek, bu iş için oldukça yaygın bir pratik olmuş (Anitha & Patil, 2022; Ezenkwu vd., 2015).

Peki, bu ikili neden bu kadar tuttu? Sanırım en büyük sebep pratik olması. RFM, o karışık veriyi alıp R, F, M gibi üç basit sayıya indiriyor (Lin & Wu, 2010). K-Means de bu sayıları kullanarak, çok sayıda müşteri olsa bile hızlıca çalışıp onları "Şampiyonlar", "Risk Altındakiler" gibi işe yarar gruplara ayırabiliyor (Aslantaş vd., 2023). Sadece dükkanlar da değil; bankalar (Chitra & Heikal, 2024) veya kargo firmaları (Özcan, 2023) bile kullanmış. Yani anlaşılan epey esnek bir yöntemdir.

Ama tabii ki, bu yöntemler her derde deva değil. Bunu da kabul etmek lazım. RFM mesela, genelde sadece satılan mala odaklanıyor. Müşterinin siteyi gezmesi veya sepeti terk etmesi gibi başka şeyleri pek görmüyor (Gomes vd., 2023; Shirole vd., 2021). K-Means'in de bazı dertleri yok değil. Belki de en baş ağrıtanı, en başta 'kaç gruba ayırayım?' ('K' sayısı) sorusuna sizin cevap vermenizi beklemesi. Bu sayıyı bulmak da her zaman öyle kolay olmuyor.

Peki bu 'K' sayısı sorunu nasıl çözülüyor? Geliştirilmiş bazı yöntemler var tabii. Literatürde en sık karşımıza çıkanlardan biri Dirsek (Elbow) Yöntemi; pratik olduğu için sıkça kullanıldığı anlaşıyor (Shirole vd., 2021; Alzami vd., 2023). Yalnız, Dirsek yöntemi her zaman çok net bir 'dirsek' göstermeyebiliyor. İşte bu yüzden, bulunan kümelerin gerçekten ne kadar iyi olduğunu anlamak için Siluet Skoru (Silhouette Score), DBI veya CHI gibi başka testlere de bakmak gerekiyor gibi duruyor (Anitha & Patil, 2022; Fauzan & Alfian, 2024; John vd., 2023). Ayrıca K-Means'in başka dertleri de var : aykırı değerlerden (outliers) kolayca etkilenmesi mesela (John vd., 2023; Savic vd., 2019). Ve başlangıç noktasına göre farklı sonuçlar verebilmesi de akılda tutmak lazım (Bandyopadhyay vd., 2021).

Sonuçta ne diyebiliriz? Evet, bu zorluklar var. CLV tahmini, Hiyerarşik Kümeleme, Derin Öğrenme gibi daha ileri yöntemler de geliştiriliyor. Yine de RFM ve K-Means ikilisi, davranışsal müşteri segmentasyonu için geçerliliğini koruyor gibi duruyor. Hızlı ve yorumlanabilir bir temel yaklaşım sunuyor.

KAYNAKÇA

- [1] Alzami, F., Sambasri, F. D., Nabila, M., Megantara, R. A., Akrom, A., Pramunendar, R. A., Prabowo, D. P., & Sulistiyawati, P. 2023. "Implementation of RFM method and K-Means algorithm for customer segmentation in e-commerce with Streamlit", *ILKOM Jurnal Ilmiah*, 15 (1), 32–44.
- [2] Anitha, P., & Patil, M. M. 2022. "RFM model for customer purchase behavior using K-Means algorithm", *Journal of King Saud University - Computer and Information Sciences*, 34 (5), 1785–1792.
- [3] Aslantaş, G., Gençgöl, M., Rumelli, M., Özaraç, M., & Bakırlı, G. 2023. "Customer segmentation using K-Means clustering algorithm and RFM model", *Dokuz Eylül Üniversitesi Mühendislik Fakültesi Fen Ve Mühendislik Dergisi*, 25 (74), 491–503.
- [4] Awaliyah, D. A., Prasetyo, B., Muzayanah, R., & Lestari, A. D. 2024. "Optimizing customer segmentation in online retail transactions through the implementation of the K-Means clustering algorithm", *Scientific Journal of Informatics*, 11 (2), 539–548.
- [5] Ballestar, M. T., Grau-Carles, P., & Sainz, J. 2018. "Customer segmentation in e-commerce: Applications to the cashback business model", *Journal of Business Research*, 88, 407–414.
- [6] Bandyopadhyay, S., Thakur, S. S., & Mandal, J. K. 2021. "Product recommendation for e-commerce business by applying principal component analysis (PCA) and K-means clustering: benefit for the society", *Innovations in Systems and Software Engineering*, 17 (1), 45–52.
- [7] Chitra, J., & Heikal, J. 2024. "Customer segmentation using the K-Means clustering algorithm in foreign banks in Indonesia", *Journals Institute of Accounting Research and Novation (IARN)*.
- [8] Doğan, O., Aycin, E., & Bulut, Z. A. 2018. "CUSTOMER SEGMENTATION BY USING RFM MODEL AND CLUSTERING METHODS: A CASE STUDY IN RETAIL INDUSTRY", *International Journal of Contemporary Economics and Administrative Sciences*, 8 (1), 1–19.
- [9] Ezenkwu, C. P., Ozuomba, S., & kalu, C. 2015. "Application of K-Means algorithm for efficient customer segmentation: A strategy for targeted customer services", *International Journal of Advanced Research in Artificial Intelligence*, 4 (10), 40–44.
- [10] Fauzan, R. M., & Alfian, G. 2024. "Segmentasi pelanggan e-commerce menggunakan fitur recency, frequency, monetary (RFM) dan algoritma klasterisasi K-Means", *JISKA (Jurnal Informatika Sunan Kalijaga)*, 9 (3), 170–177.
- [11] Gomes, M. A., & Meisen, T. 2023. "A review on customer segmentation methods for personalized customer targeting in e-commerce use cases", *Information Systems and e-Business Management*, 21 (3), 527–570.
- [12] Govindaraj, R., Ramkumar, J., Bhuvanewari, J., Venugopal, S., Chandra Kala, S. K., & Karthick, R. 2024. "Enhancing customer segmentation insights by using RFM + discount proportion model with clustering algorithms", *International Journal of Advanced Computer Science and Applications*, 15 (3), 856–862.

- [13] Govindaraj, R., Ramkumar, J., Bhuvaneswari, J., Venugopal, S., Chandra Kala, S. K., Ramasamy, V., & Karthick, R. 2025. "Enhancing customer segmentation: RFM analysis and K-Means clustering implementation", S. P. J. Christydass, N. Nurhayati, & S. Kannadhasan (Eds.), *Hybrid and Advanced Technologies: Proceedings of the International Conference on Hybrid and Advanced Technologies (ICHAT 2024)*.
- [14] Idowu, S., & Kattukottai, S. 2020. "Customer segmentation based on RFM model using K-Means, Hierarchical and Fuzzy C- Means clustering algorithms", *ResearchGate*.
- [15] John, J. M., Shobayo, O., & Ogunleye, B. 2023. "An exploration of clustering algorithms for customer segmentation in the UK retail market", *Analytics*, 2 (4), 809–823.
- [16] Kadir, M. F. A., & Achyar, A. 2019. "Customer segmentation on online retail using RFM analysis: Big data case of Bukku.id", *Proceedings of the International Conference on Environmental Awareness for Sustainable Development (ICEASD)*.
- [17] Khajvand, M., Zolfaghar, K., Ashoori, S., & Alizadeh, S. 2011. "Estimating customer lifetime value based on RFM analysis of customer purchase behavior: Case study", *Procedia Computer Science*, 3, 57–63.
- [18] Li, P., Wang, C., Wu, J., & Madleňák, R. 2022. "An e-commerce customer segmentation method based on RFM weighted K-means", *2022 International Conference on Management Engineering, Software Engineering and Service Sciences (ICMSS)*, 61–68.
- [19] Lin, S. Y., & Wu, H. H. 2010. "A review of the application of RFM model", *African Journal of Business Management*, 4 (19), 4199–4206.
- [20] Mammadov, T., & Mammadova, F. 2025. "Behavioral segmentation of customers: RFM model and K-Means application", *EURASIA: Economics & Business*, 3 (93), 13–32.
- [21] Özcan, T. 2023. "CUSTOMER SEGMENTATION USING RFM ANALYSIS AND CLUSTERING ALGORITHMS IN EXPRESS DELIVERY INDUSTRY", *Eurasian Business & Economics Journal*, 32 (32), 47–56.
- [22] Sarkar, M., Puja, A. R., & Chowdhury, F. R. 2024. "Optimizing marketing strategies with RFM method and K-Means clustering-based AI customer segmentation analysis", *Journal of Business and Management Studies*, 6 (2), 54–60.
- [23] Savic, A., Bjelobaba, G., Janicijevic, S., & Stefanovic, H. 2019. "An application of PCA based K-Means clustering for customer segmentation in one luxury goods company", *Proceedings of the UBT International Conference*.
- [24] Shah, N. H., Khalid, W., Ahmad, A., Ghaffar, J. A., & Tahir, M. 2023. "The effect of customer relationship management on customer retention: The mediating role of customer satisfaction and effective commitment", *ResearchGate*.
- [25] Shirole, R., Salokhe, L., & Jadhav, S. 2021. "Customer segmentation using RFM model and K-Means clustering", *International Journal of Scientific Research in Science and Technology*, 8 (3), 591–597.
- [26] Syahra, Y., Fadlil, A., & Yuliansyah, H. 2025. "Customer segmentation using RFM and K-Means clustering to support CRM in retail industry", *Sinkron : Jurnal Dan Penelitian Teknik Informatika*, 9 (3), 1120–1131.
- [27] Tabianan, K., Velu, S., & Ravi, V. 2022. "K-Means clustering approach for intelligent customer segmentation using customer purchase behavior data", *Sustainability*, 14 (12), 7243.
- [28] Vo, B. G., Van, H. D. S., Van, N. D., & Huynh, H. D. 2025. "Customer segmentation: Automatic K-Optimization and RFM-Based K-Means clustering", *Proceedings of the 2025 5th International Conference on AI, Mechatronics and Surveying (AIMS '25)*.
- [29] Wong, C. G., Tong, G. G., & Haw, S. C. 2024. "Exploring customer segmentation in e-commerce using RFM analysis with clustering techniques", *Journal of Telecommunications and the Digital Economy*, 12 (3), 97–125.
- [30] Wu, Z., & Jin, L. 2022. "Research on segmenting e-commerce customer through an improved K-Medoids clustering algorithm", *Computational Intelligence and Neuroscience*, 2022, 9930613.